FIAP

RELATÓRIO TÉCNICO

Alexandre Natã Vicente
Antônio Cláudio Almeida
Cyd Ferreire Rodrigues
David Catherink
Marcelo Macedo Klotz

FIAP - Postech em IA para Devs

1 Sumário

1 Sobre o relatório 3

2 Introdução 4

2. 1 Links relacionados 4

3 Contexto e objetivos 5

4 Implementação do Algoritmo Genético 6

5 Experimentos e resultados da otimização 7

6 Integração com LLM (NLP) 8

7. Desafios e soluções 9

1.1 Sobre o relatório

Este relatório integra a **segunda fase** do Tech Challenge da Pós-Tech em IA para Desenvolvedores da FIAP. O objetivo desta etapa é evoluir a solução de Inteligência Artificial para o diagnóstico de câncer de mama, explorando técnicas avançadas de modelagem, avaliação de performance e otimização, mantendo o foco na distinção entre tumores benignos e malignos.

O grupo responsável pelo desafio é composto pelos seguintes integrantes da **Secretaria de Segurança Pública do Distrito Federal (SSP/DF)**:

- Alexandre Natã Vicente (**rm370024**) (ale.n.vicente@gmail.com)
- Antônio Cláudio Almeida (**rm370052**) (antonioalmeida@gmail.com)
- Cyd Ferreira Rodrigues (**rm370004**) (cydnelson@gmail.com)
- David Catherink (**rm369997**) (d.catherinck@gmail.com)
- Marcelo Macedo Klotz (**rm370010**) (marceloklotz@gmail.com)

2 Introdução

Dando continuidade ao trabalho acadêmico iniciado na Fase 1, esta etapa foca no refinamento dos modelos de Aprendizado de Máquina supervisionado. Utiliza-se a mesma base de dados Breast Cancer Wisconsin, abordando o problema como uma classificação binária onde o custo clínico de falsos negativos é prioritário. No entanto, para fins didáticos, foram adicionados dados demográficos como idade e etnia.

2. 1 Links relacionados

Os arquivos relacionados a este desafio podem ser acessados por meio dos seguintes endereços eletrônicos:

- **Github da Segunda Fase:** https://github.com/marceloklotz/breast-cancer-fiap-segunda-fase/
- **Base de dados original:** https://raw.githubusercontent.com/marceloklotz/breast-cancer-fiap-segunda-fase/refs/heads/main/breast-cancer.csv
- **Dados gerados para fins didáticos:** https://raw.githubusercontent.com/marceloklotz/breast-cancer-fiap-segunda-fase/refs/heads/main/dados_demograficos_aleatorios_idade_etnia.csv
- **Dados gerados pelo notebook (prompts e respostas):** https://raw.githubusercontent.com/marceloklotz/breast-cancer-fiap-segunda-fase/refs/heads/main/fase2_llm_explanations.csv

3 Contexto e objetivos

O projeto visa aprimorar o modelo de classificação binária (maligno vs. benigno) desenvolvido na Fase 1. O objetivo central desta etapa foi aplicar Algoritmos Genéticos (GA) para a otimização de hiperparâmetros e utilizar Modelos de Linguagem de Grande Escala (LLMs) para transformar dados técnicos em insights acionáveis para profissionais de saúde

4 Implementação do Algoritmo Genético

A otimização via GA foi estruturada para buscar a melhor combinação de hiperparâmetros para um pipeline composto por StandardScaler, PCA e LogisticRegression.

Codificação dos Genes: Foram otimizados os parâmetros C (força de regularização, escala logarítmica), class_weight (estratégia de balanceamento) e pca_var (variância explicada pelo PCA entre 0.90 e 0.99).

Função Fitness: O "coração" do algoritmo foi uma função de pontuação ponderada que priorizou a segurança clínica e a equidade:

Recall (45%): Prioridade máxima para minimizar falsos negativos.

Especificidade (25%): Para evitar alarmes falsos excessivos.

F1-Score (20%): Equilíbrio geral do modelo.

Equidade (10%): Medida através do gap de performance entre subgrupos demográficos simulados (idade e etnia).

Penalização: Modelos com Recall abaixo de 0.95 sofreram uma penalidade de 0.10 no score final.

Operadores Evolutivos: Utilizou-se seleção por torneio, cruzamento uniforme e mutação gaussiana/reset.

5 Experimentos e resultados da otimização

Foram realizados três experimentos variando o tamanho da população, número de gerações e taxas de mutação:

EXP1: Configuração equilibrada (pop: 10, gen: 20, mut: 0.20).

EXP2: Maior população e menor mutação (pop: 20, gen: 15, mut: 0.10).

EXP3: Mais gerações e maior mutação (pop: 10, gen: 35, mut: 0.30).

Os experimentos convergiram rapidamente para soluções similares, indicando uma região de hiperparâmetros robusta para o *dataset* utilizado. O melhor modelo obteve um Recall de 0.976 e Especificidade de 1.0, superando o baseline da Fase 1 em todas as métricas críticas, incluindo a redução do gap de equidade.

6 Integração com LLM (NLP)

Os Para melhorar a comunicação dos resultados, integrou-se o modelo **GPT-4o-mini** via API da OpenAI.

- **Abordagem:** Implementou-se ***Prompt Engineering*** para criar um assistente clínico que interpreta as predições e probabilidades do modelo, fornecendo recomendações de próximos passos sem fornecer um diagnóstico definitivo.
- **Dataset para Fase 3:** Foram geradas explicações para 25 amostras do conjunto de teste, salvas em formatos **CSV e JSONL**, preparando a base para um futuro *fine-tuning*.
- **Avaliação Qualitativa:** As respostas foram consideradas precisas, concisas e respeitosas, atendendo aos requisitos de confidencialidade e utilidade profissional.

7. Desafios e soluções

Um desafio relevante foi a ausência de dados demográficos no *dataset* original para o cálculo de equidade. A solução implementada foi a criação de um conjunto de dados simulado com idade e etnia, permitindo a demonstração da metodologia de cálculo de gaps de performance e sua inclusão na função fitness. Este trabalho demonstrou que a evolução de modelos via GA, aliada à interpretabilidade via LLMs, cria uma infraestrutura robusta para assistentes médicos avançados.

FIAP